OFI-Based Short-Horizon Machine Learning Trading Strategy

Objective

To investigate whether Order Flow Imbalance (OFI) contains predictive power for short-horizon price movements.

Methodology

- Construct OFI-based microstructure features
- Train XGBoost model to predict 1-minute price direction (Up / Flat / Down)
- Define signal: Score = P(Up) − P(Down)
- Convert predictions into ranking-based trading strategy
- Backtest with transaction cost and out-of-sample validation

Strategy Design

- Ranking-based selection (Top / Bottom K%)
- Fixed holding period (HOLD)
- Transaction cost included

Key Findings

- OFI signals show short-term alpha under strict filtering (small K)
- Alpha is concentrated at very short horizons and decays rapidly
- Out-of-sample results suggest alpha exists but lacks stability

Conclusion

The results indicate potential predictive power in OFI-based signals, while further work is required to improve robustness and practical applicability

主動買賣力不平衡（OFI）之短週期機器學習交易策略研究

Trade-based Order Flow Imbalance : A Short-Horizon Machine Learning Strategy Study

Liu Jia Wen , 2025-12

研究動機、研究假設與研究架構

1. 研究動機
   - OFI（Order Flow Imbalance）衡量市場當下主動買盤與主動賣盤的差異。
     當主動買賣力量出現明顯不平衡時，價格在短時間內可能較容易往其中一個方向移動。
2. 研究假設
   - OFI 反映主動買賣力道不平衡 ， 對未來短期價格方向有訊號
   - ML 可捕捉 OFI 與量價互動的非線性關係

3. 研究架構

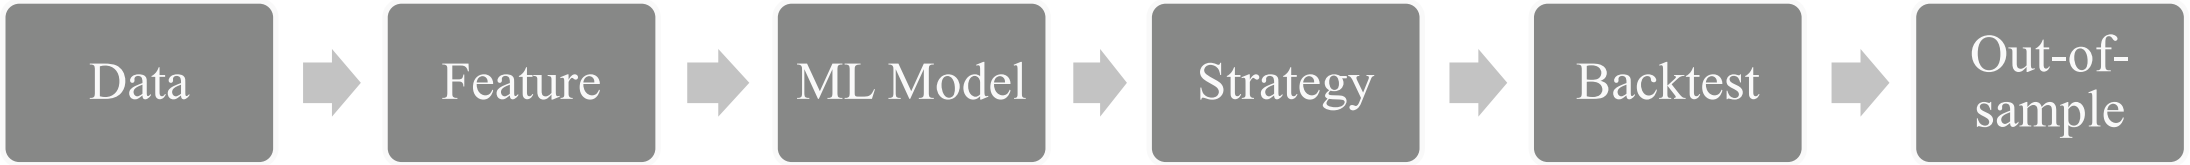

資料來源與資料流程

- 資料來源：期交所（TAIFEX）2017–2023/09 年，小型台指期貨（MTX）逐筆成交資料
- 目標資料形態：將逐筆資料重採樣為 1 分鐘資料（用於 ML 與回測）
- Training：2017–2021
- Validation（樣本內）：2022
- Out-of-sample（樣本外）：2023/01–2023/09
- 資料處理流程（Pipeline）：

特徵設計（OFI）

Feature 類別	Feature Name	中文名稱	**特徵說明**
OFI 訊號	ofi_1m	1分鐘成交單流不平衡	捕捉主動買賣力道差異（核心 Alpha）
	ofi_ratio	OFI 強度比例	強化方向性與極端買賣壓
	ofi_1m_lag1	OFI 1分鐘落後1期	捕捉短期延續性
	ofi_1m_lag2	OFI 落後2期	短線訊號記憶
	ofi_1m_lag3	OFI 落後3期	微結構動能
	ofi_1m_lag4	OFI 落後4期	降低瞬間噪音影響
成交量結構	vol_1m	1分鐘成交量	市場活躍程度
	vol_1m_lag1	成交量落後1期	量能持續性
	vol_1m_lag2	成交量落後2期	捕捉量能衝擊
	vol_1m_lag3	成交量落後3期	市場參與度變化
	vol_1m_lag4	成交量落後4期	降低短期波動
	vol_3m_avg	3分鐘平均成交量	平滑化量能噪音
報酬結構	ret_1m	1分鐘報酬率	短期 momentum / reversal
	ret_1m_lag1	報酬落後1期	動能延續
	ret_1m_lag2	報酬落後2期	捕捉反轉
	ret_1m_lag3	報酬落後3期	短期結構
	ret_1m_lag4	報酬落後4期	降低噪音
	ret_3m	3分鐘報酬	跨時間尺度動能
微波動結構	range_1m	1分鐘高低價差	Intrabar volatility proxy
	range_1m_lag1	波動落後1期	噪音狀態辨識
	range_1m_lag2	波動落後2期	高波動 regime
	range_1m_lag3	波動落後3期	微結構不穩定
	range_1m_lag4	波動落後4期	噪音過濾

ML Model

- 模型選擇 ：XGBoost multi-class classifier
- 預測目標 ：預測未來 1 分鐘價格方向（Down / Flat / Up ）
- 訊號定義：Score = P(Up) − P(Down)
- 訓練方式：時間序列切割，Training：2017–2021，Validation（樣本內回測）：2022

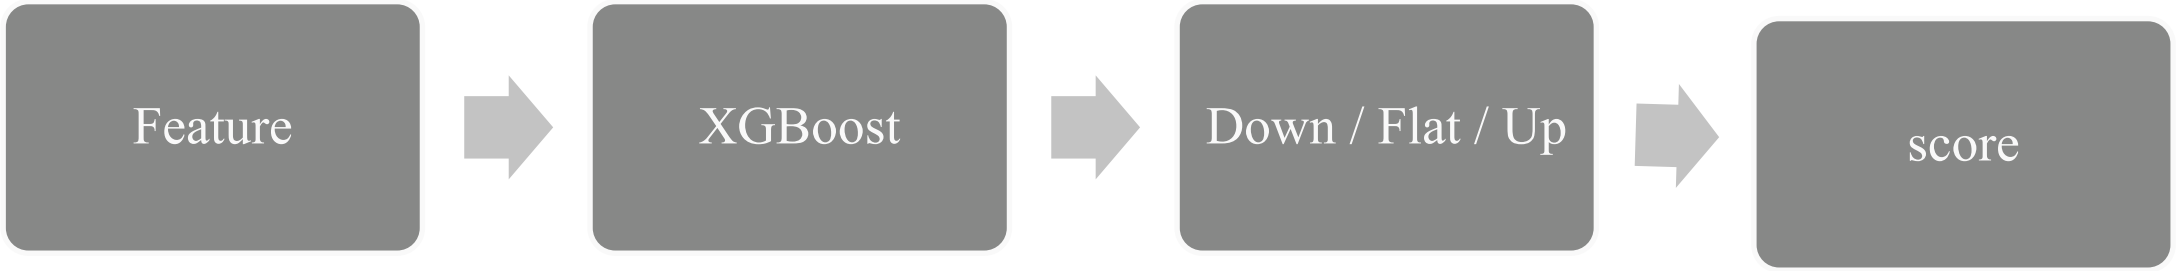

訊號排序與策略轉換

Signal Layer

訊號層：

- score = P(up) − P(down)，預測出來的上漲機率與下跌機率之差。
- 代表短期多空力量不平衡程度。
- 訊號強度越高，代表價格方向預測信心越強。

Portfolio Construction

部位建構機制：

- 每分鐘依據 Score 進行排序。
- 選取排名前 K% 作為進出場交易條件。
- Long : Top K% signals
- Short : Bottom K% signals

Execution & Exit

進場與出場邏輯：

- 於進場訊號下一分鐘進場，以確保訊號建立時間完整，並避免使用未來資料。
- 採固定 HOLD 分鐘出場機制
- 納入交易成本

樣本內參數搜尋與 Validation 回測結果（2017–2022）

- 參數設定：
  - K（訊號排名比例）： 0.5% – 20%
  - HOLD（持有分鐘數）: 10 – 90 min
- 交易成本假設：單邊手續費：0.4 point
- 主要評估指標：Sharpe_daily_point、TotalPnL_point

2022 Validation 參數組合回測績效結果（TotalPnL_point Top 5）:

K	HOLD	Sharpe_daily_point	TotalPnL_point	MaxDD_point	TotalTurnover	PnL per Trade (point)	PnL before transaction cost
0.005	10	-1.03	-821.37	1205.61	2712	-0.30	263.43
0.005	20	-1.91	-1870.40	2063.53	2712	-0.69	-785.60
0.01	10	-2.46	-2350.58	2508.73	5424	-0.43	-180.98
0.005	30	-2.42	-3482.40	3745.53	2712	-1.28	-2397.60
0.005	90	-1.30	-3532.40	4191.21	2712	-1.30	-2447.60

- 主要觀察：
  1. 所有參數組合回測結果皆未產生穩定正向 Sharpe
  2. 在 K 固定下，HOLD 時間越長，策略績效顯著下降。
  3. 在較小 K 與較短 HOLD 下，若不考慮交易成本，策略仍呈現正損益。

樣本外驗證結果(2023)

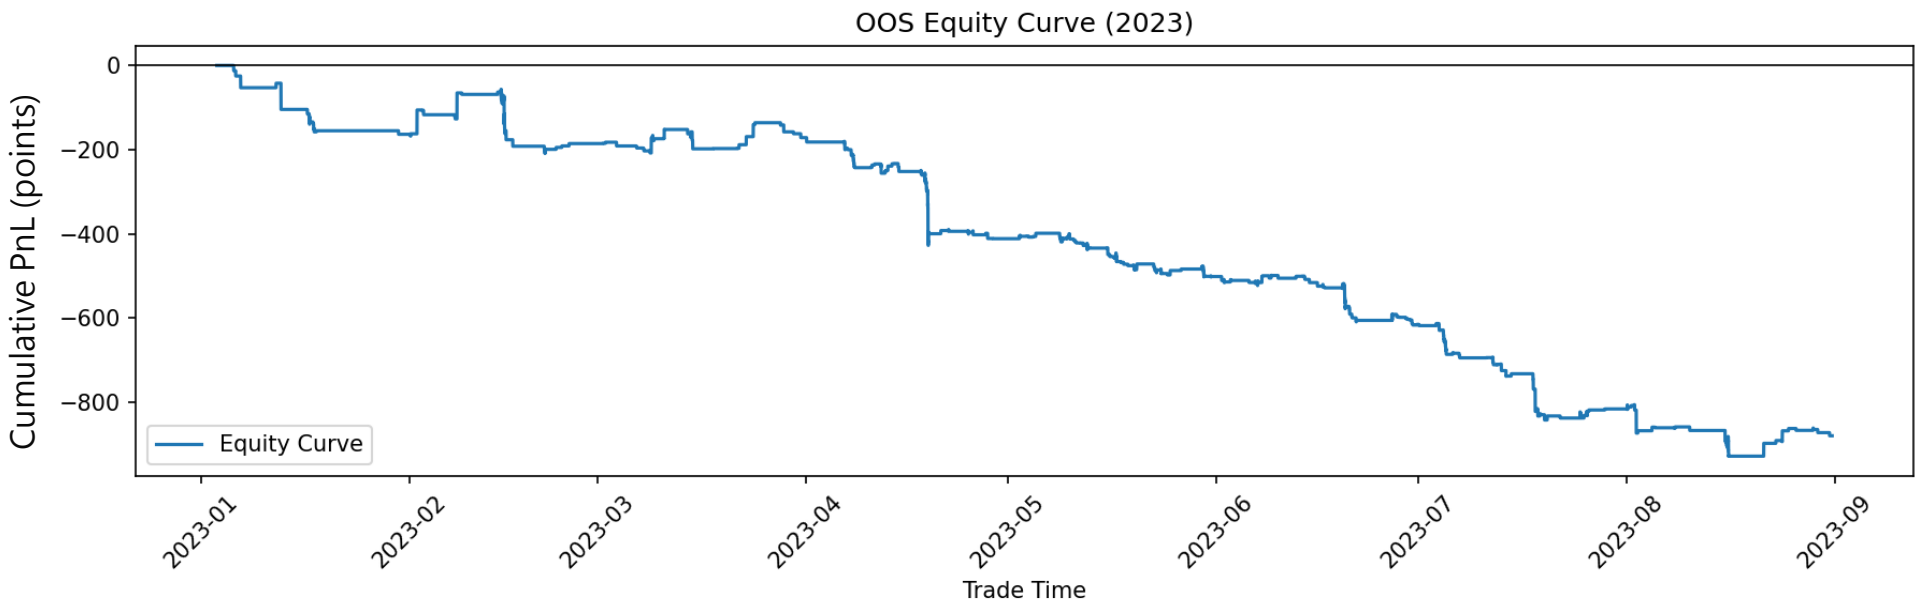

策略績效摘要表

Sharpe_daily_point	-3.66
TotalPnL_point	-879.87
MaxDD_point	928.51
TotalTurnover	1608
PnL per Trade_point	-0.55
PnL before transaction cost	-236.67

摘要：

- 使用 2017–2022 訓練所得最佳參數，未重新調整模型與策略設定，直接套用至 2023/01–2023/09，以避免過度擬合。
- 樣本外結果顯示訊號穩定性不足，策略績效為負，Sharpe 明顯低於樣本內結果，未能產生可部署的 Alpha。

研究結論與後續方向

研究結論

- OFI 訊號在較嚴格的排名門檻（較小 K）與較短持有期間下，仍呈現一定的短期預測能力。
- 研究結果顯示 OFI 在極短時間尺度可能具有預測能力，但訊號衰退速度較快。
- 在樣本外測試中，策略整體績效仍不穩定，尚未形成可部署的 Alpha。

後續優化方向

- 可進一步對交易門檻 (K) 與持有時間 (HOLD) 進行更細緻的參數搜尋與策略設計，以觀察訊號在不同持有期間的穩定性。
- 納入委託簿 (order book) 與更高頻微結構特徵，以強化模型對短期價格變動的預測能力。